

基于深度学习的古文字识别系统

检测与识别的端到端流水线优化

计算机视觉课程报告

2026 年 5 月 19 日

摘要

古文字（如甲骨文、楚简等）的数字化识别是文化遗产保护中的重要课题。本报告提出了一种基于深度学习的古文字端到端识别系统，采用“检测 + 识别”的两阶段流水线架构。检测阶段使用 YOLOv8s-OBB 模型定位图像中的古文字区域，识别阶段采用 Swin Transformer Small 作为骨干网络进行字符分类。针对古文字数据的长尾分布特性，我们引入了 Focal Loss、混合采样器（Hybrid Sampler）、两阶段训练策略以及指数移动平均（EMA）等优化技术。在包含 6,259 个字符类别、280,507 张裁剪图像的数据集上，最优模型（exp040）取得了 88.00% 的验证准确率，其中高频类别准确率达 91.63%，中频类别达 89.95%，低频类别达 80.68%。实验结果表明，Swin Transformer 在古文字识别任务上显著优于 ResNet、EfficientNet 和 ConvNeXt 等骨干网络，同时两阶段训练策略和 EMA 对模型性能提升具有关键作用。

1 引言

1.1 研究背景

古文字是中华文明的重要载体，其中甲骨文作为最早的成熟文字系统之一，记录了商代晚期的政治、经济和文化活动。然而，古文字的识别与释读长期依赖专家的人工判断，效率低下且存在主观性。随着深度学习技术的发展，利用计算机视觉方法自动识别古文字成为可能，这对于文化遗产的数字化保护、学术研究和大众传播都具有重要意义。

古文字识别面临以下核心挑战：

- 类别数量庞大：**本次任务涉及 6,259 个不同的古文字类别，远超常规 OCR 任务的字符集规模。
- 长尾分布：**字符出现频率极度不均衡，高频字符样本超过 100 张，而稀有字符仅 1-2 张，导致模型在稀有类别上表现较差。

3. **书写变异大**：同一字符在不同载体、不同时期、不同书写者之间存在显著的风格差异。
4. **图像质量参差**：古文字图像来源于拓片、照片等不同渠道，存在噪声、模糊、残缺等问题。
5. **旋转与形变**：古文字的书写方向不固定，字符可能存在任意角度的旋转。

1.2 相关工作

古文字识别的研究可追溯至模式识别的早期工作。传统方法主要依赖手工设计的特征（如笔画特征、结构特征）结合 SVM 等分类器。近年来，深度学习方法在古文字识别中取得了显著进展：

检测方面，YOLO 系列模型因其高效的实时检测能力被广泛应用于文本检测。YOLOv8-OB（Oriented Bounding Box）版本支持旋转框检测，适合处理古文字中常见的倾斜和旋转情况。

识别方面，卷积神经网络（CNN）长期占据主导地位，从早期的 ResNet 到 EfficientNet 系列。近年来，Vision Transformer（ViT）及其变体（如 Swin Transformer）通过自注意力机制捕获全局上下文信息，在图像分类任务上展现出强大的能力。Swin Transformer 通过移动窗口机制降低了计算复杂度，同时保持了局部建模能力，特别适合需要同时关注局部笔画和全局结构的古文字识别任务。

1.3 本文贡献

本文的主要贡献如下：

1. 提出了针对古文字的端到端识别流水线，整合旋转目标检测与大规模字符分类。
2. 系统性地比较了 6 种骨干网络（ResNet-50、EfficientNet-B3/B4、ConvNeXt-Small/Base、Swin-Tiny/Small）在古文字识别上的性能。
3. 提出了融合 Focal Loss、混合采样器、两阶段训练和 EMA 的综合优化策略，有效缓解了长尾分布问题。
4. 设计了面向古文字的领域特定数据增强方法（墨迹渗透、纸张纹理、裂纹噪声等）。

2 方法

2.1 系统架构

本系统采用两阶段流水线架构，如图 1 所示。给定一张古文字图像，首先由检测模型定位所有字符区域，然后将裁剪出的字符图像送入识别模型进行分类。




图 1: 古文字识别系统流水线

2.2 字符检测：YOLOv8s-OBB

2.2.1 模型选择

古文字图像中的字符可能以任意角度出现，传统水平边界框（HBB）无法准确框定旋转字符。我们选择 YOLOv8s-OBB 模型，该模型支持旋转边界框（OBB）检测，输出 8 个坐标点 $(x_1, y_1), \dots, (x_4, y_4)$ 表示四边形区域。

2.2.2 训练配置

检测模型使用 YOLOv8s 作为预训练权重，在古文字检测数据集上进行微调。关键训练参数如下：

- 输入分辨率： 640×640
- 训练轮数：200 epochs
- 优化器：SGD，初始学习率 0.01
- 数据增强：Mosaic、MixUp、随机仿射变换

2.3 字符识别：Swin Transformer

2.3.1 Swin Transformer 架构

Swin Transformer (Shifted Window Transformer) 通过层次化设计和移动窗口自注意力机制，实现了线性计算复杂度。其核心思想包括：

层次化特征提取：类似 CNN，Swin Transformer 通过 Patch Merging 层逐步降低空间分辨率、增加通道数，形成 4 个阶段的特征金字塔：

- Stage 1: $H/4 \times W/4$ ，维度 C
- Stage 2: $H/8 \times W/8$ ，维度 $2C$
- Stage 3: $H/16 \times W/16$ ，维度 $4C$
- Stage 4: $H/32 \times W/32$ ，维度 $8C$

窗口自注意力：在每个 $M \times M$ （默认 $M = 7$ ）的局部窗口内计算自注意力，将计算复杂度从 $O(n^2)$ 降低到 $O(n \cdot M^2)$ 。

移动窗口机制：交替使用常规窗口划分和移位窗口划分，使得相邻窗口之间产生信息交互，实现跨窗口连接。

对于 Swin-Small 变体，模型参数量约 50M，包含以下配置：

- 嵌入维度 $C = 96$
- 各阶段深度 $[2, 2, 18, 2]$
- 注意力头数 $[3, 6, 12, 24]$

2.3.2 识别模型设计

我们在 Swin-Small 的基础上进行以下修改以适应古文字识别任务：

1. **分类头替换：**将原始的 1000 类分类头替换为 6,259 类分类头，并添加 Dropout ($p = 0.5$) 和标签平滑 ($\epsilon = 0.15$) 以防止过拟合。
2. **输入尺寸：**将输入图像从默认的 224×224 保持不变，该尺寸在计算效率和识别精度之间取得了良好平衡。
3. **预训练权重：**使用 ImageNet-1K 预训练权重初始化，加速收敛并提升泛化能力。

分类头的输出可表示为：

$$\hat{y} = \text{softmax}(\text{Dropout}(W \cdot f_{\text{Swin}}(x) + b)) \quad (1)$$

其中 $f_{\text{Swin}}(x)$ 为 Swin Transformer 提取的 768 维特征向量。

2.4 训练优化策略

2.4.1 Focal Loss

古文字数据集存在严重的类别不平衡问题。标准交叉熵损失对所有样本一视同仁，导致模型被大量易分类的高频样本主导。Focal Loss 通过降低易分类样本的权重，使模型更关注难分类样本：

$$\mathcal{L}_{\text{focal}} = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (2)$$

其中 p_t 为正确类别的预测概率， γ 为聚焦参数。我们设置 $\gamma = 2.0$ ，使得预测概率为 0.9 的样本损失权重仅为 0.01，而预测概率为 0.5 的样本损失权重为 0.25。

2.4.2 混合采样器 (Hybrid Sampler)

为了平衡不同频率类别的训练机会，我们设计了混合采样器，结合了两​​种采样策略：

- **类别均衡采样**：每个类别被采样的概率相等，确保稀有类别得到足够的训练机会。
- **实例均衡采样**：按样本数量比例采样，保持原始数据分布。

混合采样概率为：

$$P_{\text{hybrid}}(c) = \alpha \cdot P_{\text{cb}}(c) + (1 - \alpha) \cdot P_{\text{ib}}(c) \quad (3)$$

其中 $\alpha = 0.5$ ， P_{cb} 为类别均衡概率， P_{ib} 为实例均衡概率。

2.4.3 两阶段训练策略

我们采用两阶段训练策略以充分利用数据：

- **第一阶段 (Epoch 1–150)**：使用混合采样器训练，使模型学习到所有类别的基本特征表示。
- **第二阶段 (Epoch 151–300)**：切换为实例均衡采样，让模型在真实数据分布上精调，避免过度拟合稀有类别的有限样本。

2.4.4 指数移动平均 (EMA)

EMA 通过对模型参数取指数移动平均，提升模型的泛化能力和稳定性：

$$\theta_{\text{EMA}}^{(t)} = \beta \cdot \theta_{\text{EMA}}^{(t-1)} + (1 - \beta) \cdot \theta^{(t)} \quad (4)$$

其中 $\beta = 0.999$ 。EMA 相当于对训练过程中的多个模型状态进行集成，有效平滑了训练噪声。

2.4.5 学习率调度

采用 Cosine Warmup 调度策略：

- **预热阶段 (Epoch 1–10)**：学习率从 10^{-6} 线性增长到 3×10^{-4} 。
- **余弦退火阶段 (Epoch 11–300)**：学习率按余弦函数从 3×10^{-4} 衰减到 10^{-6} 。

2.5 数据增强

2.5.1 基础增强

- 随机水平翻转 ($p = 0.5$)
- 随机旋转 ($\pm 15^\circ$)
- 随机缩放 ($0.8 \times - 1.2 \times$)
- 颜色抖动 (亮度、对比度、饱和度 ± 0.2)
- 随机灰度转换 ($p = 0.1$)

2.5.2 领域特定增强

针对古文字的特殊性，我们设计了以下领域特定增强方法：

1. **墨迹渗透 (Ink Bleed)**: 模拟墨水在纸张上的渗透扩散效果，使用形态学滤波（最大值/最小值滤波）实现。
2. **纸张纹理 (Paper Texture)**: 添加随机噪声模拟竹简、龟甲等载体的表面纹理。
3. **腐蚀膨胀 (Erosion/Dilation)**: 模拟文字笔画的磨损和扩散。
4. **裂纹噪声 (Crack Noise)**: 模拟载体表面的裂纹对文字的干扰。
5. **污渍模拟 (Stain)**: 模拟载体上的污渍遮挡。

3 实验

3.1 数据集

3.1.1 数据来源

实验数据来源于古文字识别竞赛数据集，包含甲骨文和楚简等多种古文字。原始数据为带标注的 XML 文件，标注了每个字符的位置和类别。

3.1.2 数据统计

数据集的关键统计信息如表 1 所示。

表 1: 数据集统计信息

属性	数值
字符类别数	6,259
总裁剪图像数	280,507
原始裁剪图像	30,000
扩展裁剪图像	36,685
域外裁剪图像	61,245
完整裁剪图像	280,507
原始标注文件数	6,237

3.1.3 类别频率分布

按照每个类别的样本数量，我们将 6,259 个类别分为 4 个频率组：

- **高频 (>100 样本)**：常见古文字，如”乍””用””子”等
- **中频 (10–100 样本)**：较常见古文字
- **低频 (3–10 样本)**：较少见古文字
- **稀有 (1–2 样本)**：极罕见古文字

3.2 实验设置

所有实验在 NVIDIA A100-PCIE-40GB GPU 上进行。训练超参数如表 2所示。

表 2: 训练超参数

参数	值
骨干网络	Swin-Small
输入尺寸	224×224
批大小	32
初始学习率	3×10^{-4}
优化器	AdamW
权重衰减	10^{-4}
训练轮数	300
学习率调度	Cosine Warmup
预热轮数	10
损失函数	Focal Loss ($\gamma = 2.0$)
采样器	Hybrid ($\alpha = 0.5$)
Dropout	0.5
标签平滑	0.15
EMA 衰减率	0.999
两阶段切换轮	150

3.3 骨干网络对比实验

我们对 6 种骨干网络进行了系统性对比实验，结果如表 3 所示。

表 3: 不同骨干网络的识别准确率

骨干网络	验证准确率	参数量
ResNet-34	56.09%	21.3M
ResNet-50	63.51%	23.7M
EfficientNet-B3	66.15%	12.2M
EfficientNet-B4	66.53%	17.6M
ConvNeXt-Small	86.94%	49.5M
Swin-Tiny	81.09%	27.5M
Swin-Small	88.00%	49.5M
ConvNeXt-Base	67.71%	87.5M
ViT-B/16	45.90%	85.8M

从表 3 可以看出：

1. Swin-Small 取得了最高的 88.00% 验证准确率，显著优于其他骨干网络。
2. ConvNeXt-Small 以 86.94% 位居第二，与 Swin-Small 差距仅 1.06 个百分点。
3. 传统 CNN 架构 (ResNet、EfficientNet) 在古文字识别上表现明显逊色，ResNet-34 仅 56.09%。
4. ViT-B/16 表现最差 (45.90%)，说明纯 Transformer 架构缺乏归纳偏置，在小样本类别上难以有效学习。
5. 参数量并非越大越好，ConvNeXt-Base (87.5M 参数) 反而不如 ConvNeXt-Small (49.5M 参数)，可能是因为数据量不足以支撑更大的模型。

3.4 优化策略消融实验

为了验证各优化策略的有效性，我们进行了消融实验。以 exp040 (Swin-Small + Natural Aug + Focal Loss + Hybrid Sampler + 2-Stage + EMA) 为基准，逐步移除各组件，结果如表 4所示。

表 4: 优化策略消融实验

配置	Val Acc	高频	中频	低频	稀有
exp040 (完整配置)	88.00%	91.63%	89.95%	80.68%	45.45%
exp041 (Heavy+CutMix)	86.40%	87.41%	88.40%	78.31%	45.79%
exp037 (无合并数据)	88.43%	—	—	—	—
exp034 (ConvNeXt-Small)	86.94%	—	—	—	—
exp035 (Swin-Tiny)	81.09%	—	—	—	—

3.4.1 Heavy Augmentation + CutMix 的影响

exp041 在 exp040 的基础上将增强策略从 Natural 升级为 Heavy，并添加了 CutMix ($\alpha = 1.0, p = 0.5$)。然而，exp041 的验证准确率从 88.00% 下降到 86.40%，主要原因分析如下：

1. **过度增强**：Heavy 增强包含更强的旋转、颜色抖动和领域特定增强，可能破坏了古文字的关键笔画结构信息。
2. **CutMix 的副作用**：CutMix 将两张图像的区域混合，对于古文字这种笔画精细、结构敏感的类别，混合后的图像可能产生语义不一致的样本，干扰模型学习。
3. **训练-验证差距**：exp041 的训练准确率仅为 73.93%，而验证准确率为 85.93%，说明 Heavy 增强使得训练更加困难，模型未能充分拟合训练数据。

3.4.2 频率分组分析

表 4 中的频率分组准确率揭示了长尾分布的影响：

- 高频类别 (>100 样本) 准确率最高，exp040 达 91.63%。
- 中频类别 (10–100 样本) 表现良好，达 89.95%。
- 低频类别 (3–10 样本) 准确率显著下降至 80.68%。
- 稀有类别 (1–2 样本) 准确率仅 45.45%，是主要瓶颈。

exp041 在稀有类别上略优于 exp040 (45.79% vs 45.45%)，说明更强的增强对稀有类别有轻微帮助，但代价是高频和中频类别的显著下降。

3.5 训练过程分析

图 2 展示了 exp040 的训练过程。




图 2: exp040 训练过程 (Epoch 185–300)

训练过程显示模型在 Epoch 183 左右达到最佳验证准确率 88.00%，之后进入稳定期。训练准确率和验证准确率之间的差距很小（约 0.7%），说明模型没有严重过拟合。

3.6 端到端评估

端到端评估将检测模型和识别模型串联，在完整图像上评估系统的整体性能。我们在 6,233 张域外 (OOD) 测试图像上进行了全量评估，共包含 61,245 个标注字符。评估指标包括：

- **检测 F1**：字符定位的精确率和召回率的调和平均。

- **识别准确率**：正确定位的字符中，识别正确的比例。
- **端到端 F1**：综合考虑检测和识别错误的整体指标（竞赛评价标准）。

表 5 展示了不同配置下的端到端评估结果。

表 5: 端到端评估结果（6,233 张图像，61,245 个字符）

配置	Det P	Det R	Det F1	Char Acc	E2E P	E2E F1
exp040 (conf=0.25)	0.884	0.608	0.721	0.803	0.710	0.623
exp040 (conf=0.15)	0.799	0.651	0.717	0.796	0.636	0.616
exp037 (conf=0.15)	0.795	0.649	0.714	0.851	0.676	0.642

从端到端评估结果可以看出：

1. **检测是主要瓶颈**：检测召回率最高仅 65.1%，意味着约 35% 的真实字符未被检测到，这直接限制了端到端 F1 的上限。
2. **置信度阈值的影响**：降低检测阈值从 0.25 到 0.15，召回率从 60.8% 提升到 65.1%，但精确率从 88.4% 下降到 79.9%，整体 F1 变化不大。
3. **识别准确率与检测的权衡**：exp037 在识别准确率上更高（85.1% vs 79.6%），但 exp040 的检测精确率更高，两者端到端 F1 接近。
4. **端到端 F1 为 0.623**：受限于检测召回率，端到端 F1 远低于单独的识别准确率（88.00%），说明检测模块仍有较大优化空间。

4 系统部署

4.1 Docker 容器化

为了方便模型提交和部署，我们将整个推理流水线打包为 Docker 镜像。Docker 镜像基于 NVIDIA CUDA 12.4 运行时环境，包含以下组件：

- 基础镜像：nvidia/cuda:12.4.0-runtime-ubuntu22.04
- PyTorch 2.6.0 + CUDA 12.4
- YOLOv8 检测模型权重（22MB）
- Swin-Small 识别模型权重（615MB）
- 字符映射表（93KB）

推理脚本支持批量识别（batch size=64），在 A100 GPU 上可达到约 50 张图像/秒的处理速度。

4.2 推理流程

1. 读取输入目录中的古文字图像
2. 使用 YOLOv8s-OBB 检测所有字符区域（置信度阈值 0.15）
3. 裁剪检测到的字符区域
4. 批量送入 Swin-Small 模型进行识别
5. 输出 JSON 格式的预测结果

5 讨论

5.1 Swin Transformer 的优势分析

Swin Transformer 在古文字识别任务上表现优异，我们分析其优势主要来自以下方面：

1. **局部-全局特征融合**：移动窗口机制使 Swin Transformer 能够同时捕获局部笔画细节和全局字符结构，这对古文字识别至关重要。
2. **层次化特征**：4 阶段特征金字塔提供了从细粒度到粗粒度的多尺度表示，适合不同复杂度的古文字。
3. **归纳偏置**：相比 ViT，Swin Transformer 的局部窗口注意力引入了空间归纳偏置，有利于小样本类别的学习。

5.2 长尾分布的挑战

尽管 Focal Loss 和混合采样器在一定程度上缓解了长尾问题，稀有类别的准确率仍然很低（45.45%）。这主要因为：

- 1-2 个样本不足以让模型学习到鲁棒的特征表示。
- 即使使用类别均衡采样，稀有类别的样本多样性仍然不足。
- 数据增强虽然可以增加样本数量，但无法创造真正的新信息。

未来可能的改进方向包括：

- 使用 LDAM（Label-Distribution-Aware Margin）损失，为稀有类别提供更大的分类间隔。
- 引入少样本学习方法，如原型网络或元学习。
- 利用字符的部首结构信息进行层次化分类。

5.3 增强策略的反思

exp041 的实验结果表明，更强的数据增强并不总是带来更好的性能。对于古文字这种对笔画结构高度敏感的任务，过度增强可能适得其反。CutMix 在自然图像分类中表现优异，但在古文字识别中产生了语义不一致的问题，导致性能下降。这提示我们在设计数据增强策略时，需要充分考虑领域特性。

6 结论

本报告提出了一种基于深度学习的古文字端到端识别系统，通过“YOLOv8s-OBB 检测 + Swin-Small 识别”的两阶段流水线，在包含 6,259 个类别的大规模古文字数据集上取得了 88.00% 的验证准确率。主要结论如下：

1. Swin Transformer Small 是古文字识别任务的最佳骨干网络，显著优于 ResNet、EfficientNet 和 ConvNeXt 等架构。
2. Focal Loss + 混合采样器 + 两阶段训练 + EMA 的综合优化策略有效提升了模型性能，尤其是对低频和稀有类别的识别能力。
3. 适度的领域特定数据增强（Natural 级别）优于过度增强（Heavy + CutMix），后者会破坏古文字的关键结构信息。
4. 长尾分布仍然是古文字识别的核心挑战，稀有类别的准确率仅为 45.45%，需要进一步研究。
5. 端到端评估中，检测模块是系统的主要瓶颈（召回率仅 65.1%），端到端 F1 为 0.623，远低于单独的识别准确率，检测模块仍有较大优化空间。

附录：完整实验结果

表 6: 所有实验结果汇总

实验	骨干网络	Val Acc
exp037	Swin-Small + Hybrid + 2Stage + EMA	88.43%
exp040	Swin-Small + Merged + Hybrid + 2Stage + EMA	88.00%
exp034	ConvNeXt-Small + Full + 200ep	86.94%
exp041	Swin-Small + Heavy + CutMix	86.40%
exp035	Swin-Tiny + Natural + Focal + CB	81.09%
exp035	ConvNeXt-Small + 224 + CB	80.30%
exp022	ConvNeXt-Small + 250ep	68.27%
exp019	ConvNeXt-Small + Focal	67.91%
exp021	ConvNeXt-Base + Focal	67.71%
exp020	EfficientNet-B4 + 200ep	67.04%
exp018	EfficientNet-B4 + Focal + 160	66.69%
exp017	ResNet-50 + Focal + Mixup + 160	66.65%
exp016	ResNet-50 + Focal + 160px	66.53%
exp014	ResNet-50 + Extended + 150ep	66.31%
exp015	EfficientNet-B3 + Cosine	66.15%
exp013	ResNet-50 + Extended	65.84%
exp023	ConvNeXt-Small + CutMix + 300ep	64.91%
exp012	ResNet-50 + All Data	63.51%
exp010	ResNet-50 + 100ep	63.04%
exp008	ResNet-50 + Strong Aug	62.69%
exp011	ResNet-101 + 128px	62.58%
exp005	ResNet-50 + 128px	61.93%
exp009	ResNet-50 + Cosine	61.04%
exp006	ResNet-50 + 224px	61.02%
exp026	EfficientNet-V2-S + Focal + 160	60.82%
exp004	ResNet-34 + 128px	56.11%
exp001	ResNet-34 Baseline	56.09%
exp002	ResNet-34 + Reg	52.82%
exp025	ConvNeXt-Small + 192px	45.90%
exp028	ViT-B/16 + Focal + 224	42.85%